DETECCIÓN EN PATRONES DE VENTA DE PRODUCTOS PARA CADENA DE LOCALES DE ROPA Y PRODUCTOS DE BELLEZA

Sobre el dataset

Los datos fueron creados para construir un sistema de recomendación basado en contenido utilizando datos de texto o de imágenes provenientes de la página web para e-comerce de una cadena de ropa localizada en India, para poder recomendar elementos similares a los usuarios.

```
#Importación de librería.
import pandas as pd
#Importación de dataset.
df=pd.read_csv("/content/fashion.csv")
print(df.head(10))
```

```
                                          ProductID  \
0  10017413,DKNY Unisex Black & Grey Printed Medi...
1  10016283,EthnoVogue Women Beige & Grey Made to...
2  10009781,SPYKAR Women Pink Alexa Super Skinny ...
3  10015921,Raymond Men Blue Self-Design Single-B...
4  10017833,Parx Men Brown & Off-White Slim Fit P...
5  10014361,SHOWOFF Men Brown Solid Slim Fit Regu...
6  10017869,Parx Men Blue Slim Fit Checked Casual...
7  10009695,SPYKAR Women Burgundy Alexa Super Ski...
8                                          10000571
9  10017421,DKNY Unisex Black Large Trolley Bag,D...

                                       ProductName ProductBrand Gender  \
0                                              NaN          NaN    NaN
1                                              NaN          NaN    NaN
2                                              NaN          NaN    NaN
3                                              NaN          NaN    NaN
4                                              NaN          NaN    NaN
5                                              NaN          NaN    NaN
6                                              NaN          NaN    NaN
7                                              NaN          NaN    NaN
8  Parx Men Brown Tapered Fit Solid Regular Trousers         Parx    Men
9                                              NaN          NaN    NaN

  Price (INR) NumImages                                  Description  \
0         NaN       NaN                                          NaN
1         NaN       NaN                                          NaN
2         NaN       NaN                                          NaN
3         NaN       NaN                                          NaN
4         NaN       NaN                                          NaN
5         NaN       NaN                                          NaN
6         NaN       NaN                                          NaN
7         NaN       NaN                                          NaN
8         664         5  Brown solid regular trousers regular trousers
9         NaN       NaN                                          NaN

  PrimaryColor;;;;;;;;
0                  NaN
1                  NaN
2                  NaN
3                  NaN
4                  NaN
5                  NaN
6                  NaN
7                  NaN
8          Red;;;;;;;;
9                  NaN
```

Ojetivo principal

Crear un sistema que recomiende productos expecíficamente al usuario basándose en el contenido o características de los ítems que el busca.

Exploración del dataset

```
#Información general del dataset.
print(df.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 12761 entries, 0 to 12760
Data columns (total 8 columns):
 #   Column                Non-Null Count  Dtype
---  ------                --------------  -----
 0   ProductID             12761 non-null  object
 1   ProductName           1981 non-null   object
 2   ProductBrand          1980 non-null   object
 3   Gender                1942 non-null   object
 4   Price (INR)           1938 non-null   object
 5   NumImages             1937 non-null   object
 6   Description           1937 non-null   object
 7   PrimaryColor;;;;;;;;  1936 non-null   object
dtypes: object(8)
memory usage: 797.7+ KB
None
```

Diccionario de variables

- ProductID: identificador único para cada producto.
- ProductName: nombre del producto
- ProductBrand: marca del producto.
- Gender: género al que está dirigido el producto.
- Price (INR): precio del producto en rupia india.
- NumImages: número de imágenes del producto en la página de e-comerce de la cadena.
- Description: descripción del producto.
- PrimaryColor;;;;;;;;: color que predomina en el producto.

En cuanto a columnas, contiene 8, descriptas anteriormente, donde todas son variables del tipo categóricas.

A su vez contiene 12761 filas, con varios valores nulos en la mayoría de las columnas con excepción de la variable "ProductID", por lo que se requerirá una limpieza en este aspecto.

```
#Verificación
print(df.isnull().sum())
```

```
ProductID                   0
ProductName             10780
ProductBrand            10781
Gender                  10819
Price (INR)             10823
NumImages               10824
Description             10824
PrimaryColor;;;;;;;;    10825
dtype: int64
```

Aquí se muestra específicamente la cantidad de valores nulos en cada columna.

En relación a valores únicos es lógico que los encontremos en cantidad considerando que todas las variables son categóricas. Se analizará uno por uno en la sección "limpieza de datos" de este proyecto con el objetivo de unificar y normalizar variables de ser necesario.

```
#Demostración de valores únicos.
print(df.nunique())
```

```
ProductID               12506
ProductName              1677
ProductBrand              268
Gender                     12
Price (INR)               577
NumImages                  10
Description              1615
PrimaryColor;;;;;;;;       40
dtype: int64
```

Limpieza de datos

- Eliminación de valores nulos

```
#Eliminación
df=df.dropna()
```

```
#Verificación
print(df.isnull().sum())
```

```
ProductID               0
ProductName             0
ProductBrand            0
Gender                  0
Price (INR)             0
NumImages               0
Description             0
PrimaryColor;;;;;;;;    0
dtype: int64
```

- Eliminación de duplicados

```
#Eliminación
df_clean = df.drop_duplicates()
```

Normalización de datos

-Renombre de columnas

```
#Columna "PrimaryColor;;;;;;;;"
df = df.rename(columns={'PrimaryColor;;;;;;;;': 'PrimaryColor'})
```

```
#Columna "Price (INR)""
df = df.rename(columns={'Price (INR)': 'Price'})
```

```
#Verificación
print(df.info())
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 1936 entries, 8 to 12759
Data columns (total 8 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   ProductID     1936 non-null   object
 1   ProductName   1936 non-null   object
 2   ProductBrand  1936 non-null   object
 3   Gender        1936 non-null   object
 4   Price         1936 non-null   object
 5   NumImages     1936 non-null   object
 6   Description   1936 non-null   object
 7   PrimaryColor  1936 non-null   object
dtypes: object(8)
memory usage: 136.1+ KB
None
```

- Renombre de categorías de la columna "PrimaryColor"

```
#Visualización de datos únicos.
df['PrimaryColor'].unique()
```

```
array([' Red;;;;;;;;', 'Blue;;;;;;;;', ';;;;;;;;', ' White;;;;;;;;',
       ' Gold;;;;;;;;', ' Brown;;;;;;;;', ' Black;;;;;;;;',
       ' Grey;;;;;;;;', ' Pink;;;;;;;;', ' Silver;;;;;;;;',
       ' Burgundy;;;;;;;;', ' Green;;;;;;;;', ' Mustard;;;;;;;;',
       ' Matte;;;;;;;;', ' Yellow;;;;;;;;', ' Maroon;;;;;;;;',
       ' Beige;;;;;;;;', ' Khaki;;;;;;;;', ' Purple;;;;;;;;',
       ' Orange;;;;;;;;', ' Peach;;;;;;;;', ' Navy;;;;;;;;',
       ' Lavender;;;;;;;;', ' Charcoal;;;;;;;;', 'Blue;;;;;;;', ' Beige;',
       'Blue;', ' Red;', ' Black', ' Black;', ' Red', ' Green', ' Pink',
       ' Black;;;;;;;', ' Black;;;;', ' Rose;;;;;;;;', ' Green;;;;;;;',
       ' Platinum;;;;;;;;', ' Bronze;;;;;;;;', ' Gold;;;;;;;'],
      dtype=object)
```

```
#Renombre de las categorías de la columna "PrimaryColor"
df['PrimaryColor'] = df['PrimaryColor'].replace({' Red;;;;;;;;': 'Red','Blue;;;;;;;;': 'Blue',"White;;;;;;;;":"White", "Go
```

```
#Verificación
df['PrimaryColor'].unique()
```

```
array(['Red', 'Blue', ';;;;;;;;;', ' White;;;;;;;;', ' Gold;;;;;;;;',
       ' Brown;;;;;;;;', 'Black', ' Grey;;;;;;;;', ' Pink;;;;;;;;',
       ' Silver;;;;;;;;', 'Burgundy', ' Green;;;;;;;;', 'Mustard',
       ' Matte;;;;;;;;', ' Yellow;;;;;;;;', ' Maroon;;;;;;;;',
       ' Beige;;;;;;;;', ' Khaki;;;;;;;;', 'Purple', ' Orange;;;;;;;;',
       ' Peach;;;;;;;;', ' Navy;;;;;;;;', ' Lavender;;;;;;;;', 'Charcoal',
       ' Beige;', ' Red;', ' Black', ' Black;', ' Red', ' Green', ' Pink',
       ' Black;;;;;;;', ' Black;;;;', ' Rose;;;;;;;;', ' Green;;;;;;;',
       'Platinum', 'Bronze', ' Gold;;;;;;;'], dtype=object)
```

```
#Renombre de las categorías de la columna "PrimaryColor" #2
df['PrimaryColor'] = df['PrimaryColor'].replace({" White;;;;;;;;":"White"," Gold;;;;;;;;":"Gold", " Brown;;;;;;;;":"Brown",
```

```
df = df[df['PrimaryColor'] != ';;;;;;;;']
```

```
#Verificación
df['PrimaryColor'].unique()
```

```
array(['Red', 'Blue', 'White', 'Gold', 'Brown', 'Black', 'Grey', 'Pink',
       'Silver', 'Burgundy', 'Green', 'Mustard', 'Matte', 'Yellow',
       'Maroon', 'Beige', 'Khaki', 'Purple', 'Orange', 'Peach', 'Navy',
       'Lavender', 'Charcoal', ' Green', 'Rose', 'Platinum', 'Bronze'],
      dtype=object)
```

- Eliminación de columnas insignificantes para mi objetivo

```
#Eliminación
df = df.drop(columns=['ProductID', 'Description'])
```

```
#Verificación
print(df.info())
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 1632 entries, 8 to 12755
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   ProductName   1632 non-null   object
 1   ProductBrand  1632 non-null   object
 2   Gender        1632 non-null   object
 3   Price         1632 non-null   object
 4   NumImages     1632 non-null   object
 5   PrimaryColor  1632 non-null   object
dtypes: object(6)
memory usage: 89.2+ KB
None
```

- Conversión de tipo de datos

```
#Conversión de la columna "Price" de tipo categórica a float.
df['Price'] = df['Price'].astype(float)
```

```
#Verificación
print(df.info())
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 1632 entries, 8 to 12755
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   ProductName   1632 non-null   object
 1   ProductBrand  1632 non-null   object
 2   Gender        1632 non-null   object
 3   Price         1632 non-null   float64
 4   NumImages     1632 non-null   object
 5   PrimaryColor  1632 non-null   object
dtypes: float64(1), object(5)
memory usage: 89.2+ KB
None
```

```
#Conversión de la columna "NumImages" de tipo categórica a float.
df['NumImages'] = df['NumImages'].astype(int)
```

```
#Verificación
print(df.info())
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 1632 entries, 8 to 12755
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   ProductName   1632 non-null   object
 1   ProductBrand  1632 non-null   object
 2   Gender        1632 non-null   object
 3   Price         1632 non-null   float64
 4   NumImages     1632 non-null   int64
 5   PrimaryColor  1632 non-null   object
dtypes: float64(1), int64(1), object(4)
memory usage: 89.2+ KB
None
```

Visualización de datos

- Importación de librerías

```
import matplotlib.pyplot as plt
import seaborn as sns
```

- Conteo de valores únicos de la columna "Gender"

```
df['Gender'].value_counts().plot(kind='bar',color="pink")
```

```
<Axes: xlabel='Gender'>
```

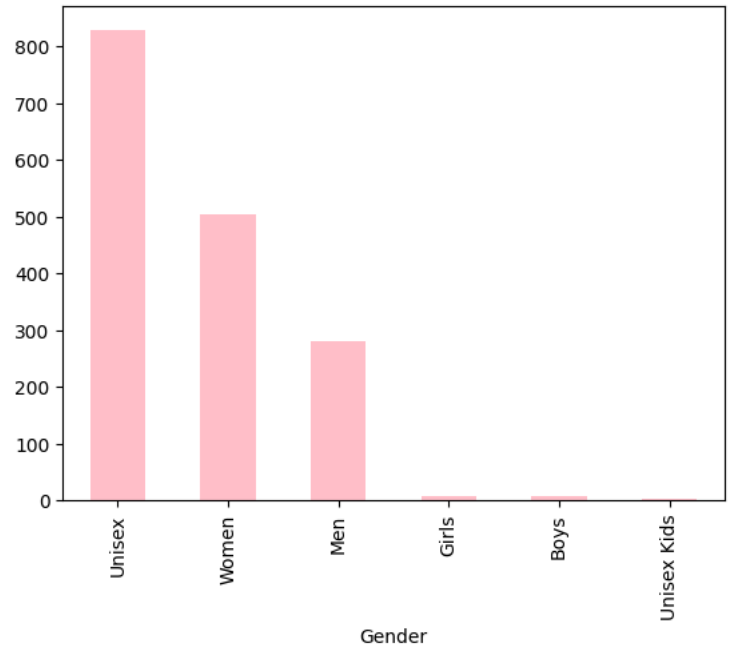

Este gráfico de barras muestra un conteo de valores únicos en la columna "Gender". Nos permite visualizar cuales son estos y cual predomina en el dataset. Se observa que la categoría "Unisex" lidera las ventas, mientras que "Unisex Kids" es la menos vendida dentro de estos locales. Esto podría influir en la recomendación inicial de la plataforma de e-comerce a los usuarios.

-Conteo de valores únicos de la columna "PrimaryColor"

```
df['PrimaryColor'].value_counts().plot(kind='bar',color="pink")
```

```
<Axes: xlabel='PrimaryColor'>
```

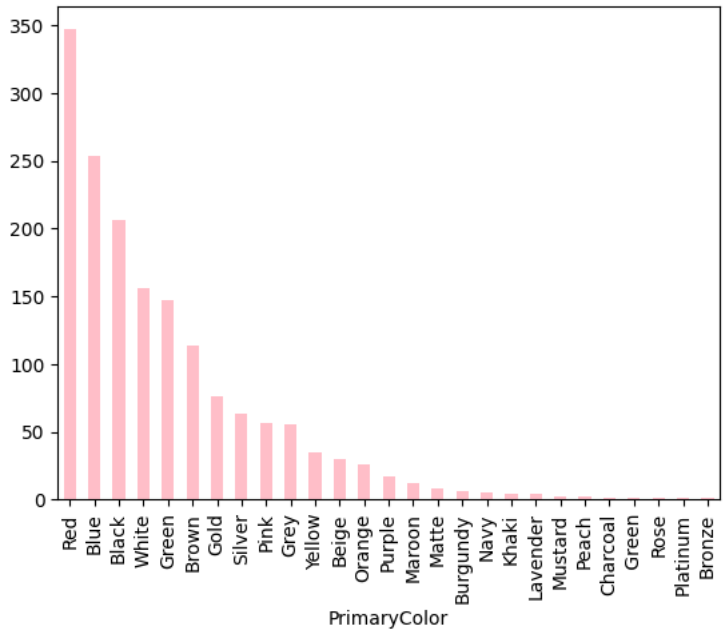

En este gráfico de barras observamos los valores únicos de la columna "PrimaryColor". De todos ellos, se destaca la categoría "Red", siendo la menos exitosa "Bronze", es decir, aparece menos veces en la página de e-comerce ya que los usuarios buscan menos sa categoría de color d ropa.

- Relación entre la variable "Price" y "NumImages"

```
df.plot(kind='scatter', x='Gender', y='Price',color="pink")
```

```
<Axes: xlabel='Gender', ylabel='Price'>
```

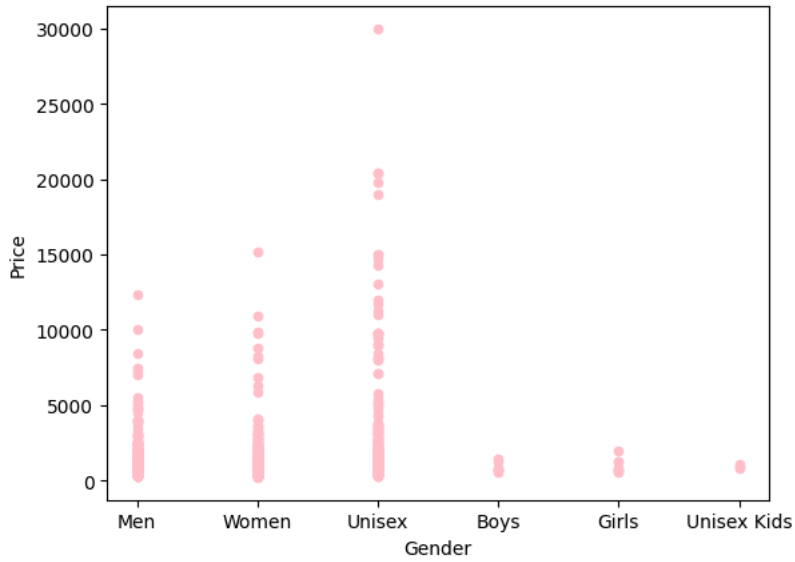

La imagen de arriba es un gráfico de dispersión que muestra la relación entre el género y el precio del producto. Se observa que los que son del género unisex, tienden a ostar más que el resto, siendo los más baratos los del género unisex para niños.Esto se condice con la menor cantidad de producto en esta categoría.

Análisis estadístico

-Variables cuantitativas

```
#Descripción estadística general
df.describe()
```

	Price	NumImages
count	1632.000000	1632.000000
mean	1344.034314	4.318015
std	1992.824634	1.120554
min	199.000000	1.000000
25%	559.000000	4.000000
50%	799.000000	4.000000
75%	1381.250000	5.000000
max	29998.000000	9.000000

La columna "Price" muestra una mediana de 799, con precios que van desde 559 a 1381 rupias indias. Sin embargo, el promedio es de 1344, ya que el valor máximo es de 29998, es decir, hay valores mucho más altos de los que se encuentran dentro del rango normal, que pueden distorcionar el análisis.

```
#Análisis de la dispersión visual.
df.boxplot(column='Price')
```

```
<Axes: >
```

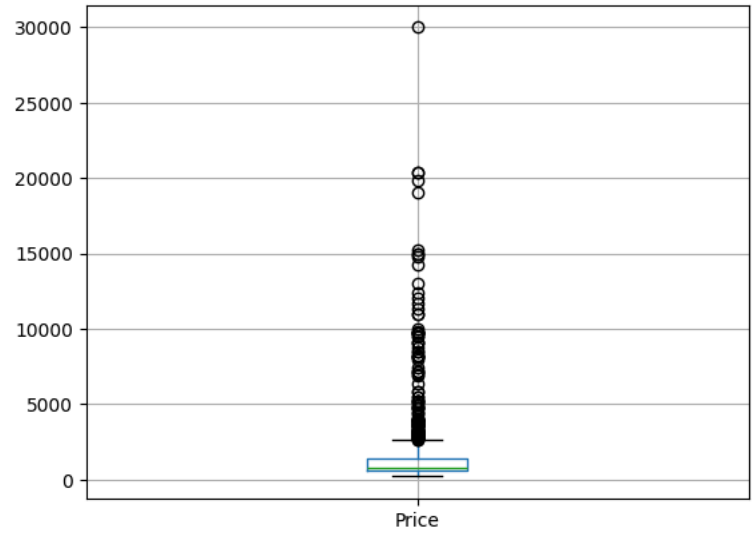

En el gráfico de dispersión anterior, confirmamos la presencia de outliers.

En cuanto a la columna "NumImages", la mediana es de 4, con un rango normal de valor que va desde 4 a 5 imágenes de cada producto. El promerio se condice con este rango, por lo que solo hay algunos valores exremos de 9 imágenes.

```
df.boxplot(column='NumImages')
```

```
<Axes: >
```

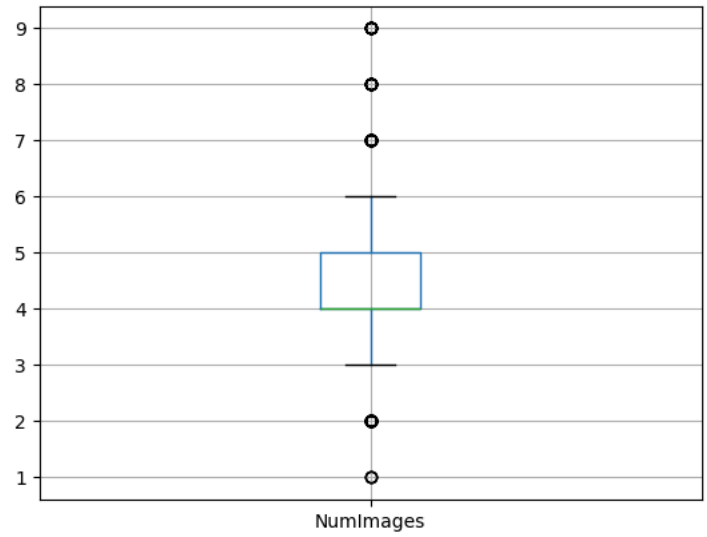

En el diagraba de caja y bigote anterior, podemos visualizar lo ya explicado sobre esta variable.

```
#Correlación entre la variable "Price" y "NumImages"
df.corr(numeric_only=True)
```

	Price	NumImages
Price	1.000000	0.119268
NumImages	0.119268	1.000000

La relación entre estas dos variables es débil.

-Variables cualitativas

```
#Frecuencia de categorías de la columna "ProductName"
df['ProductName'].value_counts()
```

ProductName	count
JEWEL JUNCTION Silver-Toned Geometric Cufflinks	12
JEWEL JUNCTION Gold-Toned Geometric Cufflinks	8
Homesake Gold-Toned & White Solid Handcrafted Table Lamp with Shade	8
Archies Love Gifts White & Black Ceramic Mug for Valentine	8
Homesake Gold-Toned Solid Handcrafted Table Lamp with Shade	7
...	...
VRINDA Yellow Single Door Curtain	1
OBSESSIONS Set of 2 Yellow Bath Rug	1
Cortina Multicoloured Geometric 120 TC Cotton 1 Queen Bedsheet with 2 Pillow Covers	1
Unravel India Brown Ceramic Cylindrical Table Top Planter	1
KLEIO Red Solid Sling Bag	1

1415 rows × 1 columns

dtype: int64

La variable "ProductName" presenta una alta cantidad de valores únicos , con baja frecuencia de repetición en la mayoría de los casos, lo que indica una alta cardinalidad y poca recurrencia de productos específicos.

```
#Frecuencia de categorías de la variables "ProductBrand"
df['ProductBrand'].value_counts()
```

ProductBrand	count
Cortina	108
SEJ by Nisha Gupta	96
Soumya	86
Archies	75
Puma	46
...	...
Chopard	1
PRITA	1
SWISS MILITARY	1
Saadgi	1
Laceandme	1

238 rows × 1 columns

dtype: int64

La columna "ProductBrand" presenta 238 valores únicos, de los cuales el que más veces aparece en el dataset es la marca "Cortina", y las marcas "Chopard,PRITA,SWISS MILITARY,Saadgi y Laceandme" solo se vendieron una vez cada una.

```
#Frecuencia de las categorías de la variable "Gender"
df['Gender'].value_counts()
```

Gender	count
Unisex	829
Women	505
Men	280
Girls	8
Boys	7
Unisex Kids	3

dtype: int64

Esta tabla de frecuencias demuestra lo analizado anteriormente en la sección "Visualización de datos", donde la categoría "Unisex" es la que más se vende en el catálogo.

```
#Frecuencia de las categorías de la variable "PrimaryColor"
df['PrimaryColor'].value_counts()
```

PrimaryColor	count
Red	347
Blue	254
Black	206
White	156
Green	147
Brown	114
Gold	76
Silver	63
Pink	57
Grey	56
Yellow	35
Beige	30
Orange	26
Purple	17
Maroon	12
Matte	8
Burgundy	6
Navy	5
Khaki	4
Lavender	4
Mustard	2
Peach	2
Charcoal	1
Green	1
Rose	1
Platinum	1
Bronze	1

dtype: int64

Esta tabla de frecuencias muestra que el color que más vende es el rojo, mientras que los productos de color "Charcoal, Green,Rose,Platinum,y Bronze" solo se vendieron una vez.

Preprocesamiento del dataset

-Eliminación de variables irrelevantes para el proyecto

```
df = df.drop(columns=['ProductName'])
```

```
#Verificación
print(df.info())
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 1632 entries, 8 to 12755
Data columns (total 5 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   ProductBrand  1632 non-null   object
 1   Gender        1632 non-null   object
 2   Price         1632 non-null   float64
 3   NumImages     1632 non-null   int64
 4   PrimaryColor  1632 non-null   object
dtypes: float64(1), int64(1), object(3)
memory usage: 76.5+ KB
None
```

Modelo de machine learning

Teniendo en cuenta mi objetivo (crear un sistema que recomiende productos expecíficamente al usuario basándose en el contenido o características de los ítems que se busca),corresponde utilizar un modelo de aprendizaje no supervisado, ya que no hay variable target.

```
#Selección de variables
df2= df[['ProductBrand', 'Gender', 'PrimaryColor', 'Price','NumImages']]
```

```
#Codificación de variables categóricas como variables ficticias.
features_encoded = pd.get_dummies(features, columns=['ProductBrand', 'Gender', 'PrimaryColor'])
```

```
#Escalar precio
from sklearn.preprocessing import MinMaxScaler
scaler = MinMaxScaler()
```